

Análisis exploratorio de la calibración de sensores del IoT

Isabella Rodriguez y Santiago Conde*

Universidad Industrial de Santander

Cra. 27 calle 9 Ciudad Universitaria, Bucaramanga

26 de Septiembre, 2025

Índice

1. Introducción	2
2. Metodología	3
2.1. Tablas	6
2.2. Figuras	7
3. El experimento y los resultados	8
4. Conclusiones y Recomendaciones	11
5. Referencias	12

Resumen

Este informe propone un método fiable para la calibración de sensores del Internet de las Cosas (IoT), los cuales miden fenómenos físicos en tiempo real y desde diversos lugares a un bajo costo. La importancia de la calibración de estos sensores reside en que su bajo precio tiene desventajas como la baja calidad en las mediciones reportadas.

En este proyecto se buscó calibrar sensores de estaciones IoT de la concentración de $PM_{2.5}$ en el ambiente, un material particulado que perjudica la salud humana. Para la calibración, se usaron como referencia las mediciones de una estación AMB. Primero, se halló la distancia entre los datos de ambas estaciones al emplear la técnica de promedios móviles. A continuación, se realizó la calibración mediante ajuste lineal entre los promedios locales de las estaciones y se evaluaron el coeficiente de determinación, error medio absoluto, distancia euclidiana y alcances. Este procedimiento se repitió para modelos entrenados con el 50 %, 35 % y 20 % de datos y probados con los restantes.

A partir del respectivo análisis, se encontró que la mejor ventana para los promedio locales corresponde a aquella con un ancho de 720 [min] y paso de 360 [min]. Además, el modelo lineal del 100 % disminuye errores y distancia pero presenta bajo alcance. En cuanto a los modelos

*e-mail: irbarrera2005@gmail.com, santicondebenavides1206@gmail.com

entrenados, el del 50 % optimiza errores y distancia, mientras que el de 20 % prioriza alcances. Estos resultados demostraron que técnicas simples de calibración pueden mejorar en gran medida la fiabilidad de los sensores IoT.

1. Introducción

La sociedad actual se halla inmersa en un proceso de desarrollo industrial acelerado en el cual la mayoría de objetos cotidianos están interconectados: desde autos hasta electrodomésticos. Esto es resultado del “boom” de una red conocida como el Internet de las Cosas (IoT), la cual enlaza aparatos físicos y electrónicos a partir del internet. La importancia de esta red reside en su capacidad de rastrear y medir fenómenos físicos a partir de sensores de bajo costo, en tiempo real y con la posibilidad de medir desde diversos puntos del planeta [1].

Gracias a sus beneficios, esta tecnología ha sido ampliamente usada en diversas áreas. Un excelente ejemplo son las estaciones IoT que miden la concentración de material particulado de $2.5\mu m$ de diámetro o menor, conocido como $PM_{2,5}$. Este es una mezcla de finas partículas inhalables en el aire que generalmente provienen de la combustión de materiales [2]. La medición de estos contaminantes es fundamental para evitar sus efectos adversos en la salud humana, como daño pulmonar y asma, y que pueden aparecer incluso con menos de 3 días de exposición [3].

A pesar de la gran utilidad de estos sensores, su bajo costo puede implicar mayor incertidumbre en las mediciones. Así, algunas estaciones IoT pueden no estar correctamente calibradas y reportar mediciones incorrectas. Por ende, las estaciones de IoT mal calibradas pueden poner en riesgo la salud de las personas o la economía de una empresa, razón por la cual es fundamental emplear un sistema de referencia para corregir las mediciones de estos dispositivos. En este contexto surge el problema de cuantificar el error de medición de los sensores IoT y hallar la forma más óptima para calibrarlos a partir de una estación de referencia.

En este orden de ideas, el objetivo de este estudio explorativo era estructurar un método de comparación entre los datos reportados por una estación IoT y una de referencia con el fin de calibrar los sensores del IoT y aprovechar su gran cobertura espacial sin perder precisión. Para llevar a cabo este proyecto, se tomaron las medidas de la concentración de $PM_{2,5}$ reportadas por estaciones IoT y por una estación AMB de referencia. De esta manera, el presente estudio establece un método eficiente y replicable para calibrar mediciones a partir de ventanas móviles en busca de un equilibrio entre reducción de ruido y resolución temporal. Además, genera las bases de un modelo de calibración para sensores IoT y su alcance dado un nivel de tolerancia definido frente a la estación de referencia. Así, este enfoque no solo mejora la calidad de los datos del IoT, sino que ofrece una técnica para proveer información fiable para gestión ambiental y la protección de la salud pública.

El desarrollo de este informe investigativo se divide en 3 secciones: en la Sección 2 se discute el método de ventanas móviles empleado para identificar la distancia entre los datos de las estaciones, y la estrategia de calibración junto a su alcance dada una tolerancia; en la Sección 3 se presentan los resultados del proceso experimental y su respectivo análisis; y se finaliza el artículo con las conclusiones del estudio en la Sección 4.

2. Metodología

Organización de mediciones y análisis gráfico inicial

Para este trabajo se emplearon con las mediciones reportadas por la estación de AMB del sector de Acualago y por la estación de sensores del IoT. Los datos

se subieron los archivos correspondientes a un Notebook de Google Collaboratory¹ en el cual se desarrollaron todos los cálculos con el fin de emplear Python y sus bibliotecas Panda y Numpy para manejar los datos con mayor facilidad. Además, ya que las mediciones de Iot se hallaban en archivos separados, se unieron en uno solo y se graficaron las mediciones de ambas estaciones con el propósito de obtener una vista global de la situación que se buscaría calibrar (Ver Figura 1).

Cálculo del promedio móvil

Para el proceso de calibración, se trazó como primer objetivo hallar la distancia entre las medidas de la estación de referencia (AMB) y las de bajo costo (IoT). Al inspeccionar las medidas, se destacó que las del IoT no ocurren al comienzo de cada hora, como las del AMB, sino que suelen ocurrir cada 55-65 minutos. En consecuencia, se consideró fundamental hallar una técnica que permitiera comparar los datos “más cercanos” entre las estaciones. Para esto, se empleó el cálculo del promedio móvil pues “suaviza” las rápidas y ruidosas variaciones en las mediciones de las estaciones IoT y genera promedios locales comparables para revelar la tendencia de la concentración de $PM_{2,5}$ a lo largo del tiempo. Esta técnica es apropiada para hallar una diferencia más estable entre los sensores, pues otros métodos pueden ser menos robustos para generar los pares de datos y no aptos para el objetivo de calibrar. De esta manera, se definió un ancho de ventana y un tamaño de paso a partir de:

$$\xi_j = a_j + \frac{(b_j - a_j)}{2} \quad (1)$$

donde j indica el número de ventanas, $(b_j - a_j)$ el ancho y a_j el paso. El ancho de ventana indica qué tanto se suavizan los datos: una ancho de 3 horas recoge los datos en ese intervalo pero suaviza menos que uno de 12 horas; y el paso indica cada cuánto se repite el cálculo: un paso más pequeño genera mayor solapamiento entre las ventanas. En este orden, se llevó a cabo el código que permitiera calcular la media de cada ventana de las estaciones de AMB y del IoT a partir de un ancho y paso dados. A continuación, se hallaron las ventanas de AMB y del IoT emparejadas (que ambas contaran con datos) pues, como se observa en la Figura 1, los archivos suministrados no cuentan con las mediciones de $PM_{2,5}$ de las estaciones IoT entre mediados de diciembre de 2018 y comienzos de abril de 2019.

Determinación de distancia: análisis del ancho de ventana y paso

Después de determinado el conjunto de ventanas emparejadas, se calculó la distancia entre las mediciones con base en la distancia euclídea:

$$\mathcal{D}(f(\xi_j), \hat{f}(\xi_j)) = \sqrt{\sum_{j=0}^N \left(f(\xi_j) - \hat{f}(\xi_j) \right)^2} \quad (2)$$

¹<https://colab.research.google.com/drive/1HDBxqdAfQNQkXcZqFFX-t57atTlnP9UX?usp=sharing>

donde $f(\xi_j)$ y $\hat{f}(\xi_j)$ representan los promedios locales en cada ventana para ambas estaciones y N el número de ventanas dados un ancho y paso. Además, se calculó el Error Absoluto Medio (EAM), el cual es un tipo de métrica que, en este caso, permite hallar el error promedio por ventana entre los promedios locales que se calcularon para cada estación. Este se calcula a partir de

$$MAE = \frac{1}{N} \sum_{j=0}^N |d_j| \quad (3)$$

donde d_j es la diferencia entre los promedios locales para cada ventana. La razón detrás del uso del EAM desde este punto del proyecto reside en que, a comparación de otras métricas, este es un error de fácil interpretación que permite tratar las variaciones en las mediciones de $PM_{2,5}$ de una manera uniforme, sin dar más importancia a ciertas mediciones que a otras pues la idea es hallar un modelo de calibración general [4]. Además, al variar el ancho y el paso, el número de ventanas varía y más ventanas implica una distancia más grande. En consecuencia, depender solo de la distancia calculada para comparar diferentes pares de ancho y paso no es ideal. Así, el EAM es un indicador de cuánto difiere el promedio las mediciones IoT y AMB sin importar cuántas ventanas se hayan calculado. Por último, se registró una tabla (Ver Tabla 1) en la que se reportaron los resultados de número de ventanas, distancia euclidiana, EAM y tiempo de ejecución del código con el fin de comparar algunos pares “(ancho, paso)”. A partir de ellos se determinó el mejor ancho y paso para la ventana.

Primer paso en la calibración: modelo de ajuste lineal

Una vez se obtuvo el ancho de ventana y paso óptimo para la calibración, se inició el proceso de calibración: primero, se graficaron los promedios locales de cada estación y se realizó regresión lineal sobre estos (Ver Figura 2). La idea consistió en tomar los valores de referencia AMB como función de los valores de las estaciones de IoT, es decir, se halló el escalar que los relaciona linealmente, el cual correspondería al factor de calibración del sensor de bajo costo. Cabe mencionar que se forzó a que el modelo tuviera intercepto nulo en el eje y, pues se debía garantizar que cuando la concentración del $PM_{2,5}$ fuera nula ambos sensores lo reportaran así. En el caso de haber tomado un intercepto distinto de 0, un sensor reportaría contaminación nula y el otro no.

Posterior al cálculo del escalar con la regresión lineal, se evaluó este modelo al compararlo con los datos de referencia de AMB y se calculó una vez más el EAM, la distancia euclidiana y se añadió el coeficiente de determinación R^2 como cálculo extra. Este coeficiente define como:

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y}_i)^2} \quad (4)$$

donde y_i es valor del promedio local de la estación AMB, \hat{y}_i es el valor predicho por el modelo lineal, y \bar{y}_i es la media de los y_i . La razón por la cual se incluyó este cálculo consiste en que R^2 indica qué tan bien se ajustaban los datos (promedios locales) al modelo lineal elegido. Si el valor de este coeficiente era cercano a 1, sería un buen ajuste, y si era cercano a 0, no era un ajuste óptimo.

A partir de este punto, se determinó el alcance de validez del modelo lineal generado para las mediciones del sensor de baja calidad y para el tiempo de medición. En primera medida, se definió una tolerancia de $5\mu g/m^3$ ya que generalmente en ambientes urbanos con altas concentraciones de

$PM_{2,5}$ se reportan desviaciones de hasta un 10-20 % [5], y, al considerar que en el conjunto de datos las concentraciones se encuentran entre $20-80\mu g/m^3$, se deduce que definir una tolerancia de $5\mu g/m^3$ equivale a un error relativo de 6-25 %. Así, este sería un valor aconsejable y coherente para la función que se le dará al sensor. Para el alcance en los valores medidos por el sensor, se encontró el rango de valores en el que la calibración es válida, es decir, el rango de valores medidos por el sensor en los que la predicción tendrá errores menores a la tolerancia elegida. Esta misma idea se aplicó para el alcance temporal, el intervalo de fechas en las que el error es inferior a la tolerancia, es decir, el periodo de tiempo en el que se puede confiar en la calibración del sensor.

Por último, se registró una tabla (Ver Tabla 2) en la que se reportaron los resultados del modelo, la distancia euclidiana, EAM, R^2 y alcances mencionados.

Segundo paso en la calibración: modelo de ajuste lineal al entrenar distintos conjuntos de datos

Como segunda estrategia para la calibración de los sensores IoT, se dividió el conjunto de datos de promedios locales a la mitad y se entrenó el modelo con solo la primera parte del conjunto. Es decir, se repitió el proceso de regresión lineal pero solo con la mitad de los datos de AMB y del IoT (Ver Figura 2). El modelo se evaluó a partir del conjunto de datos AMB sobrante (la segunda mitad) y se realizaron los mismos cálculos de distancia euclidiana, EAM, R^2 y alcances (Ver Tabla 2). A diferencia de la etapa previa en la metodología, este nuevo modelo lineal ayuda a evaluar qué tan fuerte puede ser el modelo de calibración generado al ser construido con el 50 % de los datos. Además, evita el problema de sobreajuste, en el cual el modelo se acomoda demasiado a todos los datos con los cuales fue construido, lo cual puede causar que el modelo no generalice correctamente para corregir las futuras mediciones de las estaciones de IoT.

Posteriormente, se realizaron pruebas de esta misma índole pero solo con el 35 % y 20 % de valores iniciales para el entrenamiento del modelo: se realizaron sus respectivas gráficas (Ver Figura 2) y se registraron los cálculos hechos (Ver Tabla 2). A partir de estos resultados, se eligió el mejor modelo para tres escenarios: primero, al dar igual importancia a los errores, distancia y alcances; luego, al otorgar más peso a los errores y distancia; y por último, al dar más peso a los alcances. En este orden de ideas, se normalizó cada parámetro con el fin de analizar valores únicamente entre 0 y 1 al asociar el menor valor en el conjunto con el 0 y el mayor con el 1. El fin de esto reside en evitar trabajar con valores muy dispersos entre sí. Luego, se dieron los pesos respectivos para cada escenario:

- **Primer escenario:** se le dio un peso de 0.25 a cada parámetro luego de ser normalizado.
- **Segundo escenario:** se le dio un peso de 0.35 a los parámetros normalizados de distancia y error, y de 0.15 a los de alcance.
- **Tercer escenario:** se le dio un peso de 0.35 a los parámetros normalizados de alcance y de 0.15 a los de distancia y error.

Por último, se multiplicó el peso con el valor asignado (luego de ser normalizado) para cada parámetro, y se sumó cada uno de estos resultados en cada modelo para finalmente escoger la mejor calibración para cada situación.

2.1. Tablas

Cuadro 1: Esta tabla registra algunos de los pares (ancho, paso) calculados en la investigación con su respectivo número de ventanas generado, distancia entre mediciones, el EAM y el tiempo de ejecución del código. Se observa que ventanas anchas promedian más datos y reducen el ruido aleatorio, mientras que las más pequeñas tienen errores más altos y mayor tiempo de ejecución. Además, pasos muy pequeños implican gran solapamiento y puede generar que la información entre ventanas se vuelva redundante.

(Ancho,Paso) (<i>min</i>)	N. de Ventanas	Distancia ($\mu g/m^3$)	EAM ($\mu g/m^3$)	Tiempo (<i>s</i>)
(120,60)	3821	516.749	6.2578	39
(360,120)	1937	325.604	5.7796	18
(720, 120)	1967	302.469	5.5094	19
(720, 360)	655	174.305	5.4916	5
(720, 480)	490	149.714	5.4778	5
(1440, 720)	334	117.366	5.2892	3

Cuadro 2: Esta tabla registra los modelos, distancias euclidianas, EAM, R^2 y alcances para la regresión lineal realizada con todos los datos, el 50, 35 y 20 % de ellos. Se resalta que no necesariamente a mayor número de datos tenidos en cuenta es menor la distancia y el error o mayor los alcances. Esta idea muestra una gran similitud entre estos factores y el modelo, es decir, no hay gran diferencia entre las pendientes obtenidas.

Número de Datos	100 %	50 %	35 %	20 %
Modelo lineal	$y = 0,6253x$	$y = 0,6759x$	$y = 0,6664x$	$y = 0,6589x$
Distancia ($\mu g/m^3$)	64.9404	45.5822	52.2543	57.8754
EAM ($\mu g/m^3$)	2.0529	2.0116	2.0467	2.0571
R^2	0.5437	0.1651	0.2831	0.4253
Valor Mín. IoT ($\mu g/m^3$)	1.25	5.72	1.25	1.25
Valor Máx. IoT ($\mu g/m^3$)	35.98	34.78	34.78	35.98
Valor Mín. Temporal (yyyy-mm-dd, hora)	2018-11-04 11:32:00	2019-01-24 23:32:00	2018-12-06 23:32:00	2018-12-06 23:32:00
Valor Máx. Temporal (yyyy-mm-dd, hora)	2019-04-16 17:32:00	2019-04-16 17:32:00	2019-04-16 17:32:00	2019-04-16 17:32:00

2.2. Figuras




Figura 1: Gráficas de la concentración de $PM_{2,5}$ registrada por AMB en Acualago y por las estaciones IoT entre 2018 y 2019. Esta Figura justifica la necesidad de utilizar solo las ventanas emparejadas al hacer los pares (ancho, paso) debido a la falta de mediciones de las estaciones IoT en ciertos meses. Además, refleja la gran variación en las mediciones del IoT a comparación del AMB, lo cual recalca la importancia del uso del promedio móvil para la distancia.

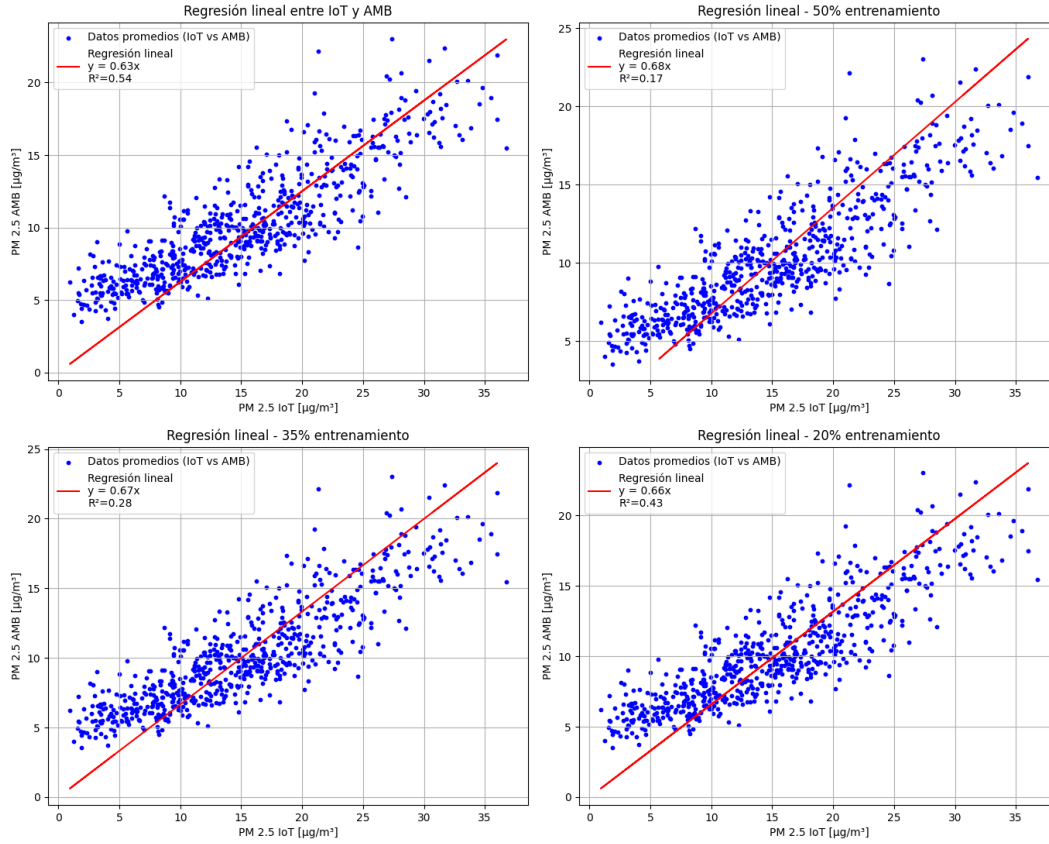


Figura 2: Gráficas de los promedios móviles de IoT y AMB, junto a las rectas de cada modelo lineal. Se evidencia la semejanza entre los cuatro modelos así como la gran dispersión de los puntos. Esto justifica los bajos valores en R^2 ya que hace complicada la existencia de un modelo que se ajuste perfectamente a estos puntos. Además, este gran número de datos variados justifica la pendiente de valor similar para los cuatro casos, aunque se haya disminuido en gran medida el número de datos tenidos en cuenta para el entrenamiento del modelo.

3. El experimento y los resultados

Una ventana de (720×360) [min] permite equilibrio entre reducción de ruido y resolución temporal

Para hallar la distancia entre las mediciones de $PM_{2.5}$ de las estaciones de AMB y del IoT, se realizó una simulación computacional con ventanas móviles debido a la discordancia temporal entre los datos de cada estación. Como se observa en la Figura 1 y partir de la inspección de las medidas, se debía definir un rango temporal común: mientras que se tenían un poco más de 7900 mediciones del AMB, solo habían un aproximado de 5000 provenientes de las IoT, y estas últimas señalan rápidas variaciones en cortos plazos que se debía suavizar con el promedio móvil.

En la Tabla 1 se observan algunos de los pares (ancho, paso) calculados para determinar el mejor

tamaño para las ventanas del promedio móvil, y es aquí donde se reflejan las limitaciones de esta técnica:

- **Ventanas pequeñas** (120 min) no filtran el ruido lo suficiente al incluir 1 o 2 mediciones por ventana, por lo cual tienen EAM más alto y tiempo de ejecución no óptimo.
- **Ventanas grandes** (720-1440 min) promedian más datos y reducen la aleatoriedad del IoT. Sin embargo, una muy ancha puede promediar demasiado y ser poco fiable para la calibración.
- **Pasos muy pequeños** respecto a su ancho generan gran solapamiento y los datos entre ventanas se repetirá hasta el punto de ser redundante. Así, el número de ventanas aumenta en una falsa sensación de más datos que no implica mayor efectividad.

Es fundamental recordar que el fin de la calibración de las estaciones IoT es tener una mayor cobertura espacial y temporal para medir la concentración $PM_{2.5}$. Además, cabe recalcar que la exposición a $PM_{2.5}$ es importante a largo y corto plazo. Este último rango, incluso en un lapso de 24 horas y en concentraciones de $5.7\text{--}177\mu g/m^3$, está fuertemente relacionado con problemas cardiovasculares, cerebrovasculares y respiratorios que pueden ser mortales [6]. Asimismo, esta corta exposición ha sido asociada a "mortalidad prematura, aumento de ingresos hospitalarios por causas cardíacas o pulmonares, bronquitis aguda y crónica, ataques de asma"[2], entre otros. Por lo tanto, se debía hallar un tamaño de ventana que permitiera una calibración ideal para lapsos entre 12-24 horas, que detectara niveles peligrosos de concentración pero que también generara los resultados esperados para efectos a largos plazos.

Con base en este análisis, se eligió una ventana de 720 minutos de ancho con un paso de 360 minutos: una ventana de 12 horas suaviza el ruido lo suficiente sin tener un número precario de ventanas, cuenta con un solapamiento moderado del 50 % y su EAM es reducido y parecido al de configuraciones con anchos más grandes. Además, cuenta con un tiempo de ejecución razonable y le da prioridad a cambios en lapsos un poco menores a 12 horas, lo cual es importante para preservar la salud de las personas expuestas a este material particulado a corto y largo plazo.

Un modelo lineal global aporta un buen nivel de precisión pero un precario alcance

El primer hecho destacable al realizar la regresión lineal con el 100 % de los datos es que la pendiente es distinta de 1, es decir, los datos de referencia de AMB son distintos a los registrados por el sensor de bajo costo, tal como se esperaba. Un escalar entre 0 y 1 indica que la relación entre estos datos es creciente y sin un aumento desproporcional del valor de las mediciones reportadas por un sensor cuando aumente el valor de las mediciones del otro.

A pesar de encontrar el modelo lineal que mejor se adaptó, el bajo R^2 visto en la Tabla 2 indica que la calidad del ajuste no es óptima. Por lo tanto, se podría esperar que alguno de los parámetros evaluados no tenga gran efectividad. Al comparar la distancia euclídea y el error medio obtenidos mediante la calibración del sensor (Ver Tabla 2) con los obtenidos al comparar los datos originales (Ver Tabla 1) se encuentra una gran diferencia: más de $400\mu g/m^3$ y $4\mu g/m^3$, respectivamente. Teniendo en cuenta que la primera magnitud otorga una perspectiva más global de la distancia entre los datos y la segunda un error más específico para cada par de datos, se destaca que la mejora fue significativa. Por lo tanto, se logró una aproximación precisa para los datos medidos, es decir, con bajo error y distancias.

Por otro lado, al observar los alcances en la Tabla 2, se resalta que el sensor recoge de forma correcta valores pequeños en la medición, ya que esta comienza a ser confiable a partir de $1.25\mu g/m^3$. Sin embargo, ésta deja de serlo al superar valores de $35.98\mu g/m^3$, un límite no tan confiable al tener en cuenta que varios datos de la medición original superan, incluso los $50\mu g/m^3$. Esto deja excluidos un gran conjunto de datos, donde el error entre la calibración del sensor y los datos reales se hace más grande que el límite óptimo. Por otro lado, el alcance temporal recoge solamente la mitad del tiempo de medición, ya que ésta comienza en octubre de 2018 y finaliza en septiembre de 2019, mientras que el periodo de fiabilidad del sensor calibrado, es decir, con errores menores a la tolerancia, es entre noviembre de 2018 y abril de 2019 para un total de 163 días. Similar a lo sucedido con el alcance en los valores detectados por el sensor, este es confiable solo en las primeras tomas de datos, ya que deja de serlo en los últimos cinco meses de medición. De esta manera, para valores muy altos de contaminación y tiempos muy prolongados, este sistema de calibración no parece ser óptimo.

Entrenar el modelo con el 50 % de datos es ideal para priorizar precisión y para dar la misma ponderación a todos los parámetros, mientras que entrenarlo con el 20 % es ideal para priorizar alcances

Todas las pendientes obtenidas en esta fase fueron muy cercanas entre sí, rondando el 0.66 (Ver Tabla 2). Al ser también cercanas a la obtenida en el paso anterior, se pueden deducir cosas similares a las ya mencionadas. Esto es coherente ya que, aunque se trabaje con menos datos, siguen el mismo comportamiento de datos, por lo tanto, esta relación sigue siendo creciente. Se esperaba que el mejor modelo al tomar solo una parte de los datos fuera el que tuvo en cuenta el 50 % de datos iniciales, luego el que tuvo en cuenta el 35 %, y por último, el del 20 % de datos, pues se consideraba que a mayor cantidad de datos, mejor sería la calibración resultante. Sin embargo, se verá que lo obtenido no siempre cumplió este patrón.

Para comenzar, cabe resaltar que el coeficiente de determinación más cercano a 1 lo tiene el modelo entrenado con el menor número de datos, mientras que el coeficiente más cercano a 0 lo tiene el modelo que se entrenó con el mayor número de datos, esto quiere decir que, a pesar de esperarse lo contrario, los datos se ajustan mucho mejor a un modelo donde no se usan tantos datos al hacer regresión lineal. En otras palabras, no es necesario ni eficiente tomar una gran cantidad de datos para obtener una recta con un ajuste apropiado. De esta manera, al analizar los resultados de distancias y errores, se encontró que el modelo con mejor precisión es el entrenado con el 50 % de datos, ya que éste tiene la menor distancia euclídea y el menor error, con valores incluso menores a los obtenidos en la fase anterior. Por consiguiente, de todos los modelos generados, éste aporta la calibración más precisa en términos de distancia y error. Es importante resaltar que, aunque el modelo menos preciso entre los tres encontrados en esta fase es el entrenado con el 20 % de datos, tiene precisión similar al modelo global ya que este último tiene mayor distancia que los tres modelos con menor número de datos tenidos en cuenta al realizar la regresión lineal pero tiene error menor que el entrenado con el 20 % de datos.

Al seguir esta línea de análisis, se encuentra que el modelo con el mejor alcance es el entrenado con el 20 % de datos pues éste tiene rangos de fiabilidad más grandes que los demás, tanto para valores de medición del sensor de bajo costo como para valores temporales. En cuanto al alcance de los valores medidos, el modelo del 20 % tiene el mismo rango del modelo lineal global, es decir,

tiene buena fiabilidad para valores pequeños de $PM_{2,5}$, mientras que para mediciones por encima de los $35.98\mu g/m^3$ esta fiabilidad se pierde. Además, el alcance temporal se encuentra entre diciembre del 2018 y abril del 2019 para un total de 130 días. Aunque recoge una gran cantidad de tiempo con una calibración confiable, este no es suficiente al considerar que las mediciones comienzan en octubre de 2018 y finalizan en septiembre de 2019. De esta manera, la calibración deja de ser fiable para periodos muy extensos de tiempo, algo similar a lo encontrado en el modelo global, pero con una pequeña diferencia de 33 días más de fiabilidad para este último modelo.

Por último, en el caso en el cual se le dio la misma importancia a todos los parámetros, se halló que el modelo más indicado es el entrenado con el 50 % de datos. Aunque éste no tuviera un gran alcance para los valores de $PM_{2,5}$ medidos y para el tiempo de medición, el modelo del 50 % cuenta con muy buena precisión que compensa la insuficiencia en el alcance. Por esto mismo, este modelo es también el óptimo al priorizar precisión, es decir, menores errores y distancias, mientras que si se prioriza alcances, el mejor modelo es el entrenado con el 20 % de datos.

Se considera necesario mencionar que, si bien se encontraron modelos que minimizan errores y distancia y que mejoran la fiabilidad del sensor, estas calibraciones tienen grandes limitaciones, tal como se observó en el coeficiente de determinación y los alcances. Esto parece deberse a la dispersión y el gran número de datos, además de la baja calidad que tuvieron las mediciones iniciales del sensor IoT. Esto genera que, aún luego de realizar la regresión lineal, sigan existiendo inexactitudes por parte de las mediciones del sensor.

4. Conclusiones y Recomendaciones

El presente informe aporta una técnica metodología de calibración de sensores IoT de bajo costo a partir de datos de estaciones de referencia AMB, esto con el fin de mejorar la confiabilidad en la medición de $PM_{2,5}$ en el medio. Se demostró que, mediante un procesamiento basado en el cálculo de promedios móviles y posteriormente una calibración lineal de los datos, es posible reducir de forma significativa la distancia y el error entre los sensores de bajo costo y los sistemas de referencia. De esta manera, el proceso de calibración llevado a cabo contribuye a la expansión de redes de monitoreo con mayor cobertura espacial y temporal.

En primera medida, los principales resultados de esta investigación indicaron que usar una ventana con ancho de 720 [min] y paso de 360 [min] era lo ideal para la calibración de los sensores. Este tamaño de ventana suavizó lo suficiente las fluctuaciones rápidas de los sensores IoT y redujo el ruido de los datos. Además, mantuvo la capacidad de detectar picos de concentración en periodos de 12-24 horas, lo cual se consideró fundamental por los graves efectos de salud que generan altas concentraciones de $PM_{2,5}$ en este rango de tiempo. Asimismo, se encontró que el modelo lineal global al calibrar los datos aporta una gran precisión, pero con un alcance limitado tanto en rango de valores como en rango temporal. Esto se concluyó a partir de la pérdida de fiabilidad en valores grandes de concentración y en periodos prolongados de tiempo.

Por otro lado, al probar entrenar el modelo con el 50 % de datos, se determinó que éste era el ideal en las situaciones en que la prioridad fuera que el sensor tuviera gran precisión en la medición de los datos y donde no sea tan trascendente su alcance. Es decir, para los casos en que se otorga más importancia al hecho de que los datos reportados por el sensor IoT sean muy cercanos al valor

real. También se encontró que este mismo modelo es ideal si se desea que tanto la precisión como el alcance tuvieran la misma relevancia. Si, por el contrario, se busca que el sensor tenga grandes rangos de fiabilidad para los valores de contaminación medida y para el tiempo de medición, el modelo más indicado sería el entrenado con el 20 %. Por ejemplo, este modelo sería útil en lugares donde la contaminación es muy grande o donde se necesitan datos con mucha diferencia en el tiempo. Esto demostró que no es necesario realizar un ajuste con todos los datos obtenidos para obtener resultados precisos y confiables, ya que otros modelos que realizan la regresión lineal con menos datos pueden llegar a ser más eficientes.

A pesar de que la calibración mejoró notablemente la precisión de los sensores IoT frente a los sensores de referencia, se presentaron insuficiencias significativas. Entre ellas destacó la pérdida de fiabilidad para concentraciones altas de $PM_{2,5}$ y para periodos prolongados de tiempo. No obstante, la reducción de errores y distancias, además de la mejora en la correlación de datos, validaron el uso de esta técnica de calibración como herramienta de apoyo.

Finalmente, este trabajo ofrece una estrategia concreta para aprovechar los sensores IoT de bajo costo en estudios de la calidad del aire, esto al ampliar la cobertura de las mediciones y permitir detectar valores críticos de contaminación que podrían perjudicar la salud humana. De esta forma, al llevar a cabo esta técnica de calibración, se contribuyó al fortalecimiento de sistemas de monitoreo ambiental en zonas urbanas, donde es de suma importancia medir la contaminación del aire para garantizar la salud pública y gestión ambiental.

5. Referencias

Referencias

- [1] D. De Cremer, B. Nguyen, and L. Simkin. *The integrity challenge of the Internet-of-Things (IoT): on understanding its dark side*. *Journal of Marketing Management*, 33:145–158, 2017.
- [2] California Air Resources Board. *Inhalable Particulate Matter and Health ($PM_{2.5}$ and PM_{10})*. <https://ww2.arb.ca.gov/es/resources/inhalable-particulate-matter-and-health>, 2025. Accedido en septiembre de 2025.
- [3] R. Brook, P. Roa, P. Levy, S. Bauer, and S.... Korzeniewski. *Estimating the number of cardio-pulmonary events potentially averted by fine particulate matter air quality index activity guidelines*. *American Journal of Preventive Cardiology*, 23:101266, 2025.
- [4] MSMK University. *Mean Absolute Error*. <https://msmk.university/mean-absolute-error/>, 2025. Accedido en septiembre de 2025.
- [5] H. Samae, P. Suriyawong, A. Yawootti, W. Phairuang, and E Sampattagul. *Precision and Accuracy Analysis of $PM_{2.5}$ Light-Scattering Sensor: Field and Laboratory Experiments*. *Atmosphere*, 16, 2025.
- [6] ESR/PHF Science. *Health Effects of Short-Term Exposure to PM , NO_2 & O_3* . <https://shortur1.at/uekPr>, 2022. Accedido en septiembre de 2025.